

Term Sheet Extractor

Guide Utilisateur

Installation, Configuration & Utilisation

Nasser Kassioui

Mars 2026

Version 2.0 — Usage Interne

Ce document explique comment installer, configurer et utiliser l'application Term Sheet Extractor. Il est destiné aux analystes, stagiaires et collègues qui doivent extraire des données structurées à partir de term sheets PDF. Aucune connaissance en programmation n'est requise.

Table des matières

1	Qu'est-ce que le Term Sheet Extractor ?	3
1.1	Objectif	3
1.2	Données extraites	3
1.3	Langues supportées	3
1.4	Émetteurs supportés	3
2	Structure du projet	3
3	Installation	4
3.1	Étape 1 — Copier le dossier sur le bureau	4
3.2	Étape 2 — Ouvrir Visual Studio Code	4
3.3	Étape 3 — Activer l'environnement Lombard Margin	5
3.4	Étape 4 — Configurer le proxy	5
3.5	Étape 5 — Naviguer vers le dossier du projet	5
3.6	Étape 6 — Installer les dépendances	5
3.7	Trouver le chemin de Python	6
4	Utilisation — Mode batch (ligne de commande)	6
4.1	Étape 1 — Placer vos PDFs	6
4.2	Étape 2 — Lancer l'extraction	6
4.3	Options disponibles	7
4.4	Étape 3 — Trouver les résultats	7
5	Utilisation — Interface web (Streamlit)	7
5.1	Démarrer l'interface	7
5.2	Utiliser l'interface	8
5.3	Comprendre le tableau de résultats	8
6	Comprendre le fichier Excel	8
6.1	Feuille 1 — Resultats	8
6.2	Feuille 2 — Underlying_ISINs	8
6.3	Comprendre les PDFs annotés	9
7	Configuration du lanceur bureau	9
7.1	Étape 1 — Copier sur le bureau	9
7.2	Étape 2 — Modifier le lanceur si nécessaire	9
7.3	Comment trouver Lombard_Margin	10
7.4	Comment trouver python.exe	10
8	Avertissements importants	10
9	Résolution des problèmes	11
9.1	« python n'est pas reconnu »	11
9.2	« streamlit n'est pas reconnu »	11
9.3	« ModuleNotFoundError : No module named pdfplumber »	11
9.4	« No PDFs found in data/input »	11
9.5	Le fichier Excel contient des valeurs vides ou incorrectes	12

9.6	Streamlit s'ouvre mais rien ne se passe après avoir cliqué sur Extract	12
9.7	L'application est très lente	12
9.8	« PermissionError » ou « Accès refusé »	12
10	Bonnes pratiques	12
11	Aide-mémoire	13

1 Qu'est-ce que le Term Sheet Extractor ?

1.1 Objectif

Le Term Sheet Extractor est un outil qui lit automatiquement des term sheets de produits structurés au format PDF et en extrait les données financières clés dans un fichier Excel propre et structuré.

Au lieu d'ouvrir manuellement chaque PDF, de chercher les champs pertinents et de copier les valeurs dans un tableur, vous déposez vos fichiers et l'outil fait le travail en quelques secondes.

1.2 Données extraites

Champ	Description
PST_ISIN	Code ISIN à 12 caractères du produit structuré
BIL	Indique si l'émetteur est la Banque Internationale à Luxembourg
CLN	Indique si le produit est un Credit Linked Note
ISSUER	Entité juridique émettrice du produit
CURRENCY	Devise de règlement (EUR, USD, CHF, etc.)
MATURITY	Date de maturité finale, au format AAAA-MM-JJ
COUPON	Taux du coupon (ex : 5,05% p.a.)
CAPITAL_PROTECTION	Pourcentage de capital garanti à l'échéance (0–100)
WORST_OR_AVERAGE	« W » (worst-of), « A » (average), ou « nan » (inconnu)
SSPA_TYPE	Code de classification SSPA à 4 chiffres
BLOOMBERG_TICKERS	Tickers Bloomberg des sous-jacents

TABLE 1 – Champs extraits de chaque term sheet

1.3 Langues supportées

L'outil supporte les term sheets en **anglais**, **français** et **allemand**. La langue est détectée automatiquement.

1.4 Émetteurs supportés

L'outil fonctionne particulièrement bien avec les term sheets de BIL, Leonteq, BNP Paribas, Goldman Sachs, UBS, Credit Suisse, Julius Baer, Vontobel et émetteurs similaires. Tout PDF avec un format clair label-valeur produira généralement de bons résultats.

2 Structure du projet

Le dossier de l'application contient les éléments suivants :

Fichier / Dossier	Rôle
<code>main.py</code>	Point d'entrée en ligne de commande. Exécutez ce fichier pour traiter les PDFs en lot.
<code>app.py</code>	Interface web (Streamlit). Propose une interface visuelle avec upload, tableau de résultats et boutons de téléchargement.
<code>launch_app.bat</code>	Raccourci Windows pour démarrer l'interface web en un double-clic.
<code>config.py</code>	Fichier de configuration. Contient tous les paramètres et seuils. Vous ne devriez pas avoir besoin de le modifier.
<code>requirements.txt</code>	Liste des packages Python nécessaires.
<code>modules/</code>	Modules de traitement internes. Vous n'avez pas besoin d'ouvrir ce dossier.
<code>data/input/</code> <code>data/output/</code>	Placez vos fichiers PDF ici avant de lancer le traitement en lot. Les résultats sont enregistrés ici : fichier Excel, PDFs annotés et fichier de log.
<code>docs/</code>	Documentation, y compris ce guide et le prompt de l'assistant.
<code>PROMPT_USERS.md</code>	Prompt pour l'assistant IA intégré. Peut être utilisé pour obtenir de l'aide.

TABLE 2 – Fichiers et dossiers du projet

3 Installation

Important

Suivez ces étapes **dans l'ordre**. Sauter une étape provoquera des erreurs. En cas de problème, consultez la Section 9.

3.1 Étape 1 — Copier le dossier sur le bureau

Accédez au dossier partagé suivant :

```
ASRINDTCREDITVAR .12 \STAGIAIRE 2026 - Nasser \PST_extractor
```

Copiez le dossier complet **Prototype V6-4.2** sur votre bureau Windows.

Pourquoi le bureau ?

Exécuter l'application directement depuis un lecteur réseau (ex : **G:**, **H:**, **S:**) est nettement plus lent et peut provoquer des erreurs de permission ou d'exécution. Il est donc recommandé d'utiliser une copie locale.

3.2 Étape 2 — Ouvrir Visual Studio Code

1. Faites un clic droit sur le dossier du projet puis sélectionnez **Open with Code**.
2. Une fois Visual Studio Code ouvert, cliquez sur **Terminal** dans la barre de menu, puis sélectionnez **New Terminal**.

3. Un terminal s'ouvrira en bas de la fenêtre. Vous pouvez désormais exécuter les commandes nécessaires.

3.3 Étape 3 — Activer l'environnement Lombard Margin

Tapez la commande suivante et appuyez sur Entrée :

```
activate Lombard_Margin
```

Vous devriez voir (Lombard_Margin) apparaître au début de la ligne de commande. Cela confirme que l'environnement est actif.

Si cette commande échoue

La commande `activate` peut ne pas être disponible si l'environnement a été configuré différemment sur votre machine. Essayez plutôt :

```
activate Lombard_Margin
```

Si cela échoue également, contactez le support IT ou le développeur.

3.4 Étape 4 — Configurer le proxy

Si vous êtes derrière un proxy d'entreprise (ce qui est le cas dans la plupart des environnements bancaires), exécutez :

```
set_proxy
```

Cela configure les paramètres réseau pour que Python puisse télécharger des packages. Si la commande n'est pas reconnue, vous pouvez passer cette étape et essayer d'installer les packages directement.

3.5 Étape 5 — Naviguer vers le dossier du projet

```
cd %USERPROFILE%\Desktop\Prototype V6-4.2
```

Vérifiez que vous êtes dans le bon dossier :

```
dir *.py
```

Vous devriez voir `main.py`, `app.py` et `config.py` dans la liste.

3.6 Étape 6 — Installer les dépendances

```
pip install -r requirements.txt
```

Cela installe les packages suivants : `pdfplumber`, `pypdf`, `openpyxl`, `streamlit` et `langid`.

Première fois uniquement

Vous n'avez besoin d'exécuter cette commande qu'une seule fois. Les packages resteront installés dans l'environnement `Lombard_Margin`. Si vous mettez à jour l'application, relancez cette commande pour vérifier que tout est à jour.

3.7 Trouver le chemin de Python

Sur certaines machines, Python peut ne pas être dans le chemin par défaut. Si des commandes comme `python main.py` renvoient « non reconnu », vous devez trouver le chemin complet de `python.exe`.

Un chemin typique ressemble à :

```
C:\localapp\apps\Python\lombard_margin\Scripts\python.exe
```

Comment le trouver :

1. Assurez-vous que l'environnement est activé (`activate Lombard_Margin`).
2. Exécutez :

```
where python
```

3. Copiez le chemin qui apparaît. Utilisez ce chemin complet au lieu de simplement `python` dans toutes les commandes.

Par exemple, au lieu de :

```
python main.py
```

Utilisez :

```
C:\localapp\apps\Python\lombard_margin\Scripts\python.exe main.py
```

4 Utilisation — Mode batch (ligne de commande)

Le mode batch traite tous les PDFs d'un dossier et produit un fichier Excel. C'est la méthode la plus rapide pour de gros volumes.

4.1 Étape 1 — Placer vos PDFs

Copiez vos fichiers PDF de term sheets dans le dossier `data/input/` à l'intérieur du projet.

4.2 Étape 2 — Lancer l'extraction

Ouvrez un terminal, naviguez vers le dossier du projet et exécutez :

```
python main.py
```

L'outil traite chaque PDF et affiche un résumé de progression.

4.3 Options disponibles

Commande	Effet
<code>python main.py</code>	Extraction complète avec PDFs annotés
<code>python main.py -no-highlight</code>	Excel uniquement, sans annotation (plus rapide)
<code>python main.py -verbose</code>	Affiche les logs détaillés pendant le traitement
<code>python main.py -input C:\chemin</code>	Utilise un dossier d'entrée personnalisé
<code>python main.py -output C:\chemin</code>	Enregistre les résultats dans un dossier personnalisé

TABLE 3 – Options en ligne de commande

Les options peuvent être combinées :

```
python main.py --no-highlight --verbose --input C:\Users\moi\pdfs
```

4.4 Étape 3 — Trouver les résultats

Les résultats sont enregistrés dans `data/output/` :

- `extraction_results.xlsx` — le fichier Excel principal avec toutes les données extraites.
- `annotated/` — dossier contenant les PDFs surlignés (sauf si `-no-highlight` a été utilisé).
- `extraction.log` — fichier de log détaillé, utile pour le diagnostic.

Accès rapide

Pour ouvrir le fichier Excel directement depuis le terminal :

```
start data\output\extraction_results.xlsx
```

5 Utilisation — Interface web (Streamlit)

L'interface web permet de déposer des PDFs, de visualiser les résultats et de télécharger les fichiers de manière visuelle.

5.1 Démarrer l'interface

Option A — Double-cliquer sur le lanceur :

Double-cliquez sur `launch_app.bat` sur votre bureau. Une fenêtre de navigateur s'ouvre automatiquement.

Option B — Depuis le terminal :

```
python -m streamlit run app.py
```

Un onglet s'ouvre à l'adresse `http://localhost:8501`.

5.2 Utiliser l'interface

1. **Upload** : Glissez-déposez un ou plusieurs fichiers PDF dans la zone d'upload, ou cliquez sur « Browse files » pour les sélectionner.
2. **Extraire** : Cliquez sur le bouton violet **Extract**. Une barre de progression indique l'avancement.
3. **Consulter** : Une fois terminé, un tableau récapitulatif affiche tous les champs extraits. Cliquez sur une ligne pour voir le détail.
4. **Télécharger l'Excel** : Cliquez sur **Download Excel results** pour enregistrer les résultats complets.
5. **Télécharger les PDFs annotés** : Dans le détail de chaque document, cliquez sur **Download highlighted PDF** pour obtenir la version annotée.

5.3 Comprendre le tableau de résultats

Colonne	Exemple	Signification
ISIN	CH1481964653	Identifiant du produit
BIL	True / False	L'émetteur est-il BIL ?
Issuer	Leonteq Securities AG	Entité émettrice
Currency	EUR	Devise de règlement
Maturity	2027-09-07	Date finale, format ISO
Coupon	5,60%	Taux du coupon
W/A	W / A / nan	Worst-of, Average ou inconnu
Cap. Prot.	0 / 100	Pourcentage de protection du capital

TABLE 4 – Colonnes du tableau récapitulatif

6 Comprendre le fichier Excel

Le fichier Excel contient deux feuilles :

6.1 Feuille 1 — Resultats

Une ligne par PDF traité. Contient tous les champs extraits ainsi que :

- `source_file` : le nom du fichier PDF original.
- `LANGUAGE` : la langue détectée (EN, FR, DE).
- `ANNOTATED_PDF` : le nom du fichier PDF annoté.

6.2 Feuille 2 — Underlying_ISINs

Une ligne par sous-jacent, relié au produit parent :

- `PST_ISIN` : l'ISIN du produit (même que Feuille 1).
- `UNDERLYING_ISIN` : ISIN du sous-jacent, si disponible.
- `BLOOMBERG_TICKER` : ticker Bloomberg (ex : GOOGL UQ, SREN SW).

Pourquoi UNDERLYING_ISIN est souvent vide ?

La plupart des term sheets identifient les sous-jacents par leur nom et leur ticker Bloomberg, pas par un ISIN. Une colonne ISIN vide avec des tickers remplis est normal et attendu.

6.3 Comprendre les PDFs annotés

Lorsque le surlignage est activé, l'outil crée des copies annotées de chaque PDF avec des surlignages colorés sur les champs extraits :

Couleur	Champ
Jaune	ISIN
Bleu clair	Émetteur
Vert clair	Devise
Rouge clair	Maturité
Violet clair	Protection du capital
Or	Coupon
Orange	Worst-of / Average

TABLE 5 – Légende des couleurs

Chaque surlignage inclut un **commentaire infobulle** expliquant pourquoi le champ a été surligné. Survolez un surlignage dans votre lecteur PDF pour lire le commentaire.

Exemples de commentaires :

- « *Capital Protection inferee via SSPA 1260 => 0%* » — la protection du capital n'était pas indiquée explicitement dans le document ; elle a été déduite du type de produit SSPA.
- « *Un seul sous-jacent => W par défaut* » — le worst-of a été déterminé car un seul sous-jacent a été trouvé.
- « *Produit BIL YES => 100% capital protection* » — le produit est un BIL YES, ce qui implique automatiquement une protection totale.

7 Configuration du lanceur bureau

Le fichier `launch_app.bat` permet de démarrer l'interface web en un simple double-clic.

7.1 Étape 1 — Copier sur le bureau

Copiez le dossier complet du projet (y compris `launch_app.bat`) sur votre bureau.

7.2 Étape 2 — Modifier le lanceur si nécessaire

Faites un clic droit sur `launch_app.bat` et sélectionnez **Modifier**. Le fichier contient quelque chose comme :

```
@echo off
call activate Lombard_Margin
cd %~dp0
python -m streamlit run app.py
pause
```

Si votre chemin Python est différent, remplacez `python` par le chemin complet :

```
@echo off
call activate Lombard_Margin
cd %~dp0
C:\localapp\apps\Python\lombard_margin\Scripts\python.exe -m
    streamlit run app.py
pause
```

7.3 Comment trouver Lombard_Margin

Si `activate Lombard_Margin` ne fonctionne pas, essayez :

```
conda env list
```

Cela liste tous les environnements disponibles. Cherchez celui nommé `Lombard_Margin` ou similaire. Utilisez le nom exact affiché.

7.4 Comment trouver python.exe

Avec l'environnement activé, exécutez :

```
where python
```

Copiez le chemin complet qui apparaît (ex : `C:\localapp\apps\Python\lombard_margin\Scripts\py`

8 Avertissements importants

1. **La protection du capital peut être inférée.** Lorsque le PDF n'indique pas explicitement la protection du capital, l'outil la déduit du type de produit SSPA. Par exemple, le type SSPA 1230 (Barrier Reverse Convertible) implique 0% de protection. Le PDF annoté indiquera quand l'inférence a été utilisée.
2. **Le worst-of / average est heuristique.** La classification utilise la détection de mots-clés et le comptage des sous-jacents. Elle est fiable pour les produits standards mais peut produire « nan » pour des structures inhabituelles.
3. **La qualité dépend du format du PDF.** Les PDFs textuels avec un format clair label-valeur produisent les meilleurs résultats. Les documents scannés (images), les fichiers protégés par mot de passe et les formats inhabituels peuvent produire des résultats incomplets.
4. **Les produits BIL YES sont forcés.** Si l'outil détecte « BIL YES » dans le titre du document, il force automatiquement Worst-of/Average à « W » et Capital Protection à « 100% », indépendamment de ce que contient le PDF.

5. **Cet outil est une aide à l'extraction, pas un conseil financier.** Toutes les données extraites doivent être vérifiées avant utilisation dans des décisions d'investissement, des rapports réglementaires ou des communications clients.
6. **Les dates suivent la convention européenne.** Le format JJ/MM/AAAA (jour en premier) est supposé. Toutes les dates sont normalisées au format AAAA-MM-JJ.

9 Résolution des problèmes

9.1 « python n'est pas reconnu »

L'exécutable Python n'est pas dans votre PATH système.

Solution :

1. Vérifiez que l'environnement est activé :
`activate Lombard_Margin`
2. Trouvez le chemin complet :
`where python`
3. Utilisez le chemin complet dans toutes les commandes.

9.2 « streamlit n'est pas reconnu »

Streamlit n'est pas installé ou n'est pas dans le chemin.

Solution :

```
pip install streamlit
```

Puis lancez avec :

```
python -m streamlit run app.py
```

9.3 « ModuleNotFoundError : No module named pdfplumber »

Un package requis n'est pas installé.

Solution :

```
pip install -r requirements.txt
```

9.4 « No PDFs found in data/input »

Le dossier d'entrée est vide ou les fichiers n'ont pas l'extension `.pdf`.

Solution :

1. Vérifiez que vos fichiers sont dans `data\input\`.
2. Assurez-vous qu'ils se terminent par `.pdf` (pas `.PDF` ni `.pdf.pdf`).

9.5 Le fichier Excel contient des valeurs vides ou incorrectes

Causes possibles :

- Le PDF est une image scannée (pas de texte sélectionnable). Test : essayez de sélectionner et copier du texte dans votre lecteur PDF. Si vous ne pouvez pas, l'outil ne peut pas non plus.
- Le PDF a un format inhabituel (3+ colonnes, tableaux imbriqués).
- Le PDF est dans une langue autre que l'anglais, le français ou l'allemand.
- Le champ n'existe tout simplement pas dans le document (ex : les trackers n'ont pas de coupon).

Solution : Ouvrez le PDF annoté pour voir quels champs ont été détectés. Consultez le fichier de log `data\output\extraction.log` pour les messages d'erreur détaillés.

9.6 Streamlit s'ouvre mais rien ne se passe après avoir cliqué sur Extract

Solution :

- Assurez-vous d'avoir uploadé au moins un fichier avant de cliquer sur Extract.
- Vérifiez la fenêtre du terminal pour les messages d'erreur (elle reste ouverte derrière le navigateur).
- Essayez d'abord avec un seul PDF fiable pour isoler le problème.

9.7 L'application est très lente

Solution :

- Utilisez `-no-highlight` en mode batch pour passer l'annotation PDF (c'est l'étape la plus lente).
- Assurez-vous d'exécuter depuis un disque local, pas un lecteur réseau.
- Fermez les autres applications lourdes.

9.8 « PermissionError » ou « Accès refusé »

Le fichier de sortie est ouvert dans une autre application (généralement Excel).

Solution : Fermez `extraction_results.xlsx` dans Excel avant de relancer l'outil.

10 Bonnes pratiques

1. **Travaillez toujours depuis une copie locale.** Copiez le dossier du projet sur votre bureau. N'exécutez pas depuis un lecteur réseau.
2. **Fermez le fichier Excel avant de relancer.** L'outil écrase le fichier de sortie à chaque exécution. S'il est ouvert dans Excel, l'écriture échouera.
3. **Vérifiez les résultats sur un échantillon d'abord.** Lors du traitement d'un nouveau lot de PDFs, commencez par 5–10 fichiers et vérifiez les résultats avant de traiter l'ensemble.

4. **Utilisez les PDFs annotés pour le contrôle qualité.** Ouvrez les PDFs surlignés et vérifiez que les bons champs sont mis en évidence. Les commentaires infobulles expliquent la logique utilisée.
5. **Surveillez le taux de remplissage.** En fin d'exécution, l'outil affiche un résumé des taux de remplissage par champ. Un taux inférieur à 80% indique un problème potentiel.
6. **Gardez le dossier d'entrée propre.** Retirez les PDFs déjà traités de `data/input/` avant d'en ajouter de nouveaux, ou utilisez un dossier personnalisé avec `-input`. L'outil retraits tous les PDFs du dossier à chaque exécution.
7. **Utilisez le fichier de log pour le diagnostic.** Le fichier `data/output/extraction.log` contient des informations détaillées sur chaque PDF traité.

11 Aide-mémoire

Action	Commande
Activer l'environnement	<code>activate Lombard_Margin</code>
Installer les packages	<code>pip install -r requirements.txt</code>
Lancer l'extraction (avec annotations)	<code>python main.py</code>
Lancer l'extraction (Excel seul)	<code>python main.py -no-highlight</code>
Lancer avec logs détaillés	<code>python main.py -verbose</code>
Dossier d'entrée personnalisé	<code>python main.py -input</code> <code>C:\chemin\vers\pdfs</code>
Démarrer l'interface web	<code>python -m streamlit run app.py</code>
Démarrer l'interface (raccourci)	Double-clic sur <code>launch_app.bat</code>
Ouvrir les résultats	<code>start data\output\extraction_results.xlsx</code>
Voir les logs	<code>type data\output\extraction.log</code>
Trouver le chemin Python	<code>where python</code>
Lister les environnements	<code>conda env list</code>

TABLE 6 – Aide-mémoire — toutes les commandes utiles

Support

Si vous rencontrez un problème non couvert dans ce guide :

1. Consultez le fichier de log : `data\output\extraction.log`.
2. Utilisez le prompt de l'assistant IA : `docs\PROMPT_USERS.md`. Copiez son contenu dans un assistant IA (BIL Gpt, Microsoft Copilot) et décrivez votre problème.
3. Contactez le développeur de l'application.

Nasser Kassioui — Mars 2026